



"El saber de mis hijos
hará mi grandeza"

Universidad de Sonora

FACULTAD INTERDISCIPLINARIA DE CIENCIAS EXACTAS Y NATURALES
DEPARTAMENTO DE MATEMÁTICAS
LICENCIATURA EN CIENCIAS DE LA COMPUTACIÓN

PROBLEMA 2

Clustering con Restricciones Prácticas

Nombre del alumno:
Mariscal Villalobos Cesar
Fecha de Entrega: 7/11/2025

Introducción

Kmeans es un algoritmo que se encarga de minimizar la distancia de aquellos puntos que queremos clasificar, a un centroide representante a cada cluster.

La idea original de Kmeans tradicional, consiste en los siguientes 4 puntos:

1. Seleccionar k centroides C_i arbitrarios, preferentemente con una separación (grande) entre ellos, los cuales representaran a algún cluster S_i , donde $i = 1, 2, \dots, k$
2. A cada punto p de nuestro conjunto de datos D , vamos a calcular la distancia respecto al punto p hacia cada centroide $c \in C_i$. p va pertenecer al cluster S_i cuya distancia $d(p, c)$ sea menor.
3. Recalculamos los centroides, usando el promedio de los miembros del cluster.

$$C_i = \frac{1}{|S_i|} \sum_{x_n \in S_i} x_n$$

4. Repetimos los pasos 2 y 3, hasta que nuestra función de energía se mínimize:

$$E_{in} = \sum_{n=1}^N ||x_n - C(x_n)||^2$$

, donde $C(x_n)$ representa el centroide que representa al cluster donde se esta clasificado x_n

Modificación de Kmeans con restricciones

Para utilizar las restricciones must-link, cannot-link, balance, capacidad, deberemos agregar algún tipo de jerarquía, o prioridad de restricciones. Yo propongo:

1. Capacidad
2. Balance
3. Cannot-link y Must-link

Suponiendo que hay conflicto sobre las restricciones, buscare preservar las restricciones relacionadas con la capacidad o el balance, y creando modificaciones en base a estas.

El algoritmo que propongo es el siguiente:

1. Seleccionar k centroides C_i arbitrarios, preferentemente con una separación (grande) entre ellos, los cuales representaran a algún cluster S_i , donde $i = 1, 2, \dots, k$
2. A cada punto p de nuestro conjunto de datos D , vamos a calcular la distancia respecto al punto p hacia cada centroide $c \in C_i$. p va pertenecer al cluster S_i cuya distancia $d(p, c)$ sea menor.
3. Determinamos que clusters cumplen las restricciones must-link y cannot-link
4. Con los clusters validos para el punto p , vemos cuales cumplen con las restricciones de capacidad
5. Si existe alguna restricción de balanceo, aplicarla en este punto.
Si un punto es necesario retirarse de un cluster, retiraremos el que tenga la distancia al centroide más lejana, $d(p_c, c)$.

6. Recalculamos los centroides, usando el promedio de los miembros del cluster.

$$C_i = \frac{1}{|S_i|} \sum_{x_n \in S_i} x_n$$

7. Repetimos los pasos 2 - 6, hasta que nuestra función de energía se minimice:

$$E_{in} = \sum_{n=1}^N ||x_n - C(x_n)||^2$$

, donde $C(x_n)$ representa el centroide que representa al cluster donde se esta clasificado x_n

Comentarios adicionales

Existen algunos problemas al momento de tener restricciones, ya que los clusters pueden no tener una solución final.

Hay algunos casos en los que los clusters podrían no tener una solución relativa, para cierta versión i de nuestros clusteres (la clasificación relativa no permite una solución, pero puede que algun otro acomodo de nuestros puntos si permita clasificar el punto actual), como en el problema de las k-reinas, que es un problema tradicional de restricciones.

Lo que me imagino que podríamos hacer aquí, es aplicar backtracking tradicional, o aplicar fuerza bruta re acomodando los clusters de alguna otra forma.