



"El saber de mis hijos
hará mi grandeza"

Universidad de Sonora

FACULTAD INTERDISCIPLINARIA DE CIENCIAS EXACTAS Y NATURALES
DEPARTAMENTO DE MATEMÁTICAS
LICENCIATURA EN CIENCIAS DE LA COMPUTACIÓN

PROBLEMA 3

Diagnóstico Avanzado de Data Leakage

Nombre del alumno:
Mariscal Villalobos Cesar
Fecha de Entrega: 7/11/2025

Taxonomía de Leakage

Leakage temporal

Este tipo de leakage, ocurre cuando nuestros modelos contienen datos que varían respecto al tiempo. Más específicamente, ocurre cuando entrenamos un modelo con datos que se recopilaban o obtuvieron en un futuro, mayor o igual al tiempo de la característica a predecir.

Podemos pensar en un modelo que intenta predecir el clima de x día, si entrenamos nuestro modelo con datos que se midieron en ese mismo día o posteriores, esto ya puede producirnos un problema de leakage.

Puede ser problemático, porque puede generar resultados que parecen correctos, sin embargo termina entorpeciendo nuestro modelo.

Para detectarlo, podríamos plantear analizar el rendimiento del modelo, suponiendo que dividimos nuestro conjunto de datos en train y test, vemos el comportamiento en la precisión de nuestro modelo para ver si esta generalizando correctamente.

Para detectarlo, es necesario examinar las características con las que estamos entrenando el modelo, si estas tienen alguna relación temporal, especialmente si es respecto a nuestra variable a predecir.

Leakage por preprocesamiento

Ocurre en la etapa de preprocesamiento, especialmente cuando estamos procesando datos antes de separar nuestros datos de entrenamiento con los datos de prueba.

Un ejemplo de esto puede ser el normalizar variables antes separar nuestro conjunto de datos.

Otro ejemplo podría ser durante la imputación de datos, supongamos que los datos perdidos, los tratamos de recuperar siempre, utilizando una media respecto a todos los datos de nuestro conjunto completo.

Para prevenirlo, debemos separar nuestro conjunto de entrenamiento y de prueba, antes de empezar a procesar nuestro conjunto de datos, así como limpiarlo adecuadamente.

Leakage por target encoding

Target encoding nos ayuda a convertir nuestras variables categóricas en variables numéricas, utilizando el promedio de aparición de estas mismas.

El problema de esto radica en que si se usa el conjunto de datos completo, esto puede producir overfitting

Para prevenirlo, debemos primero separar nuestro conjunto de datos, y posteriormente aplicar target encoding solamente a nuestro conjunto de datos de entrenamiento.

Leakage por features que contienen información futura

Es similar a leakage temporal, sin embargo, la diferencia radica en que en nuestro conjunto de características predictivas, existe alguna variable que explícitamente utilice información futura.

Retomando el ejemplo de la predicción del clima, si en nuestro conjunto de datos existe una variable llamada "Presión atmosférica promedio del año siguiente", entonces esta variable puede afectar nuestro modelo.

Algunos de los problemas que puede ocasionar esto, es un fuerte rendimiento al predecir nuestros datos de entrenamiento y los de prueba, estas métricas no representarían la realidad y antes datos nuevos se vería un rendimiento bajo.

Una medida para prevenir esto, es verificar que nuestro conjunto de datos no contenga características que representen información en el futuro. Si esto existe, debemos separar esta variable de nuestro conjunto de entrenamiento.

Leakage por duplicación de registros

Se da cuando existen registros/datos duplicados en nuestro conjunto de datos, al momento de separar nuestro conjunto de datos, en la parte de entrenamiento pueden existir registros iguales a otros registros en nuestro

conjunto de pruebas.

Esto puede ser producido tanto por error humano como el sistema que capturo esta información, o por la propia naturaleza de donde se obtengan los registros.

Un ejemplo sería en las practicas de laboratorio de Mecánica 2 de la unison, una practica común que se realiza es medir el movimiento angular de un objeto. Las variables se registran utilizando un sensor láser que mide la velocidad del objeto cada ciertos segundos, el sensor mide muy frecuente mente, por lo que si el cuerpo que se esta analizando se mueve muy lento, pueden haber mediciones de 2 instancias de tiempo con una misma posición.

Una solución a este problema es verificar que no existan registros duplicados antes del preprocesamiento, si existen registros duplicados deberá entender la naturaleza de estos y ver como actuar.

Leakage por estratificación incorrecta

Se presenta cuando nuestros tienen alguna relación directa o indirecta, entonces al momento de separar nuestros datos en conjuntos train y test, estos datos relacionados pueden estar creando un leakage similar al producido por el leakage temporal (en caso de que estos contengan un relación temporal).

Por ejemplo, si nuestras variables tienen dependencias temporales, los conjuntos train test, podrían contener una combinación de diferentes registros.

Para prevenir este tipo de leakage, se sugiere que cada vez que se detecten este tipo de relaciones, se agrupen y se utilicé algun método similar a k-fold, para entrenar individualmente nuestro modelo por cada conjunto.

Leakage por sesgo en el muestreo

Se presenta cuando nuestros grupos de train y test están sesgados de alguna forma.

Por ejemplo, suponiendo que entrenamos nuestro modelo con ciertos registros obtenidos en latino América, intentamos predecir información con registros obtenidos en Europa.

Nuestro modelo esta especializado para hacer predicciones en latinoamerica, por lo que medir el rendimiento en otras regiones puede ser erroneo.

Checklist para evitar el Data Leakage

A continuación se presente el checklist, deberá visualizarse en un lector de pdf (fuera de los navegadores)

Verificar orden de operaciones del Pipeline: Ninguna transformación al conjunto se realiza antes de separar el conjunto de datos

El análisis del data set antes de la etapa de preprocesamiento, busca detectar correlaciones entre las características y la variable a predecir

En caso de existir datos que tienen una relación temporal, agruparlas y no manejarlas como una misma.

Ocultar características futuras del conjunto de entrenamiento.

Verificar si existe algún tipo de duplicidad en los datos o alguna agrupación temporal.

De existir el punto anterior, implementarse algún algoritmo similar a k-fold para evitar utilizar información duplicada o con dependencia temporal tanto en nuestros conjuntos train y test

Verificar que el encoding no utilicé datos del conjunto de validación

Verificar que no exista riesgo de sesgar los conjuntos train y test.

References

- [1] Santamaria, A.,(2025). *La Guía Definitiva Sin Data Leakage*. Recuperado de: <https://optim-academy.blogspot.com/2025/10/guia-definitiva-domina-one-hot-encoding.html>
- [2] Mucci, T.(s.f). *What is data leakage in machine learning?*. IBM. Recuperado de: <https://www.ibm.com/think/topics/data-leakage-machine-learning>
- [3] Kapoor, S., Narayanan, A. (2023). *Leakage and the reproducibility crisis in machine-learning-based science*. Patterns. doi-url: <https://doi.org/10.1016/j.patter.2023.100804>
- [4] Baladram, S. (2024). *Data Leakage in Preprocessing, Explained: A Visual Guide with Code Examples*. Towardsdatascience. Recuperado de: <https://towardsdatascience.com/data-leakage-in-preprocessing-explained-a-visual-guide-with-code-examples-33cbf07507b7/>